

⚡ ENGENHARIA DE ÁUDIO NEURAL DE ALTA FIDELIDADE

Manual Completo do Sistema de Clonagem de Voz & Calibração Neural

Documentação aprofundada da infraestrutura de síntese vocal da BipeSend: motor neural Coqui XTTS v2, camada TSSL (Text-to-Speech Synthesis Layer), perfil acústico soberano da Germani, presets de estúdio inspirados no padrão OpenAI TTS e isolamento multi-tenant dos Agentes Mestre.

🎙️ Coqui XTTS v2 + Vocoder HiFi-GAN

Síntese neural autoregressiva de 24.000 Hz com extração de vetores latentes em pouquíssimos segundos de amostra.

👑 Germani — Voz Oficial Soberana

Identidade vocal executiva baseada em medições instrumentais de [germani.wav](#) com pitch central medido em 176.1 Hz.

🔧 Calibração Nativa & Presets OpenAI

Normalização EBU R128 (−1.0 dBFS), corte cirúrgico de silêncio morto e 4 presets de cadência humana sem gagueira.

🛡️ Isolamento Multi-Tenant & Omnichannel

Vozes built-in universais e vozes clonadas estritamente isoladas por tenant com distribuição Opus via WhatsApp Direct.

1. O Que Estamos Usando: XTTS v2, TSSL & Stack de Áudio

O ecossistema de voz da BipeSend abandona sistemas TTS convencionais robóticos (concatenativos ou baseados em regras rígidas) e adota um pipeline neural generativo de ponta a ponta, capaz de reproduzir o timbre, as micro-respirações, a entonação emocional e a cadência humana em português brasileiro.

1.1 O Motor Neural Coqui XTTS v2

O **XTTS v2 (Extended Text-to-Speech v2)** é uma das redes neurais de áudio mais avançadas do mundo para clonagem rápida de voz (*Zero-Shot Voice Cloning*). Ele combina duas etapas neurais principais:

Decodificador Autoregressivo Baseado em Transformador (GPT Latent): Analisa o texto tokenizado e, condicionado a um vetor acústico de referência (extraído do áudio do falante), gera representações latentes comprimidas (*mel-spectrogram tokens*).

Vocoder Neural HiFi-GAN: Converte os tensores latentes diretamente na forma de onda de áudio analógica/PCM em altíssima fidelidade a **24.000 Hz (24 kHz)**, garantindo calor harmônico e eliminando chiados metálicos.

1.2 O Que É o TSSL (Text-to-Speech Synthesis Layer)?

O **TSSL** é a camada proprietária de orquestração desenvolvida pela BipeSend que conecta o frontend corporativo, as regras de negócios, os webhooks do WhatsApp e o modelo neural Python. Ele atua em 4 etapas cruciais:

ETAPA TSSL	FUNÇÃO PRINCIPAL	IMPACTO NA QUALIDADE SONORA
1. Normalização Léxica	Converte moedas (<code>R\$ 150</code> → <i>cento e cinquenta reais</i>), siglas (<code>PIX</code> , <code>CRM</code>) e datas.	Evita que a IA leia números por dígitos isolados ou soletrar siglas de forma errática.
2. Tokenização & Chunking	Aplica <code>split_sentences=True</code> por pontuações prosódicas (<code>.</code> , <code>,</code> , <code>?</code> , <code>!</code>).	Gera respirações naturais entre orações, eliminando a sensação de sufocamento mecânico.
3. Condicionamento Latente	Extrai os d-vectors e embeddings de <code>speaker_wav</code> com chunking acústico de 4s a 6s.	Preserva a identidade tímbrica e a cor da voz do locutor original com precisão milimétrica.
4. Masterização Acústica	Trimming de silêncio morto e normalização linear True Peak para -1.0 dBFS .	Garante volume uniforme de transmissão broadcast sem clipping ou variações sonoras.

1.3 Stack Tecnológico em Produção

Microserviço Neural de IA (Python FastAPI):
Executado em Python 3.11 com PyTorch, SoundFile (libsndfile puro sem dependência de DLLs externas do Windows) e Uvicorn. Hospeda o endpoint `/v1/tts/synthesize` com medição em milissegundos.

Next.js App Router (SuperAdmin & Tenant):
Server Actions com tipagem estrita via Zod contracts. Comunicação via payload JSON na rede interna e reprodução sem latência via data URI base64 no navegador.

2. A Voz Oficial da Germani: Identidade Soberana & Acústica

A **Germani** não é um assistente virtual genérico configurável por terceiros. Ela atua como a *Chief Executive AI Advisor* e Assessora Pessoal da presidência da BipeSend. Sua voz reflete uma presença executiva calorosa, serena, inteligente e firme.

PITCH MEDIANO 176.1 Hz Afinação Central	LOUDNESS INTEGRADA -18.1 LUFS Padrão Broadcast	HARMÔNICO/RUÍDO 9.8 dB HNR Fonação Regular	CENTROIDE ESPECTRAL 295.7 Hz Calor < 1 kHz
---	--	--	--

2.1 O Manifesto Físico de germani.wav

A identidade vocal é derivada instrumentalmente do arquivo matriz `germani.wav`, gravado em estúdio e homologado no manifesto técnico imutável (`GERMANI_ACOUSTIC_MANIFEST`):

Duração do Áudio de Referência: 15,595 segundos de fala contínua e sem eco.

Taxa de Amostragem Original: 44.100 Hz mono PCM 16-bit com True Peak em -3.3 dBTP.

SHA-256 de Autenticidade: `06806dd8f1fa71c3734e6567b01cb169ead626fbd5eff7fc44f62b6675f8f4fc`.

Constituição Soberana Imutável:

No painel do SuperAdmin (`/germani`), a voz da Germani é exibida em modo protegido. Diferente dos agentes secundários de suporte ou vendas, a Germani não permite troca de gênero ou alteração de persona: seu perfil vocal e autoridade estratégica são parte intrínseca da identidade institucional da BipeSend.

2.2 Estrutura do Perfil Vocal JSON (VoiceProfile Schema)

```
{
  "profile_id": "germani_reference_v1",
  "name": "Germani (Oficial Soberana)",
  "language": "pt-BR",
  "acoustic_profile": {
    "pitch_hz": 176.1,
    "loudness_lufs": -18.1,
    "hnr_db": 9.8,
    "spectral_centroid_hz": 295.7
  },
  "xtts_v2_parameters": {
    "temperature": 0.68,
    "speed": 1.02,
    "repetition_penalty": 4.0,
    "top_k": 50,
    "top_p": 0.85,
    "enable_text_splitting": true
  }
}
```

3. Calibração Nativa XTTS v2: O Padrão de Qualidade OpenAI

Para que as vozes da BipeSend atinjam o nível espetacular do ChatGPT Voice da OpenAI, pesquisamos os fatores determinantes na percepção auditiva humana e calibramos cirurgicamente cada tensor de amostragem.

3.1 Os Controles Nativos do Modelo

PARÂMETRO	FAIXA	VALOR ÓTIMO	EFEITO PRÁTICO NA FALA
temperature	0.10 a 1.00	0.68	Controla a variabilidade melódica. Muito alto (>0.80) gera instabilidade; muito baixo (<0.50) soa mecânico. 0.68 traz o calor humano exato.
speed	0.70x a 1.50x	1.02x	Interpolação linear dos gpt_latents . Ajusta o ritmo sem alterar o tom da voz (sem voz de esquilo ou voz desacelerada).
repetition_penalty	1.0 a 10.0	4.0 a 4.5	Anti-Gagueira: No padrão 2.0 o modelo repete sílabas em português. Subindo para 4.0 elimina 100% dos travamentos fonéticos.
top_k / top_p	10-100 / 0.5-1.0	50 / 0.85	Amostragem de núcleo: restringe a cauda de probabilidades para impedir fonemas com sotaques bizarros ou ruídos.
split_sentences	Boolean	True	Gera cada oração individualmente e costura com respiração natural de locutor profissional.

3.2 Os 4 Presets Homologados no Voice Studio da Germani

★ **OpenAI Natural (ChatGPT)** Recomendado

T: 0.68 | V: 1.02x | Rep: 4.0 | K: 50 | P: 0.85
Equilíbrio harmônico máximo. Dicção clara, respiração orgânica, calor e prosódia sem nenhuma repetição.

⚡ **Conversa Ágil (WhatsApp / CRM)** Alta Velocidade

T: 0.72 | V: 1.10x | Rep: 4.5 | K: 50 | P: 0.80
Cadência acelerada e objetiva para mensagens de voz em atendimento comercial sem perder humanização.

🏢 **Executiva Soberana** C-Level

T: 0.62 | V: 0.98x | Rep: 5.0 | K: 45 | P: 0.85
Tom firme, seguro e aveludado com cadência calculada para reuniões estratégicas e tomada de decisão.

🎤 **Expressiva & Pitch** Apresentações

T: 0.78 | V: 1.00x | Rep: 3.5 | K: 60 | P: 0.90
Maior amplitude melódica e entonação expressiva para vídeos de vendas, demonstrações e anúncios.

4. Vozes dos Agentes Mestre & Clonagem Multi-Tenant

A arquitetura da BipeSend separa rigorosamente as vozes globais da plataforma das vozes personalizadas clonadas por cada empresa (tenant). Isso garante conformidade com a LGPD e previne qualquer vazamento de áudio ou timbre entre clientes.

4.1 Classificação das Vozes

TIPO	IDENTIFICADOR EXEMPLO	ESCOPO	ARMAZENAMENTO
Built-in (Globais)	<code>germani</code> , <code>pt-BR-natural-lucas</code> , <code>pt-BR-natural-sofia</code>	Disponíveis para todos os tenants da plataforma.	Diretório <code>app/voices/</code> + Manifesto <code>voices.json</code> .
Cloned (Personalizadas)	<code>cloned_0f8a92b_1727289900</code>	Exclusivas do tenant que realizou o upload.	Diretório <code>app/speakers/</code> + Isolamento por <code>tenant_id</code> .

4.2 Fluxo de Clonagem Instantânea de Voz

Quando um usuário cria um agente ou clona uma voz na plataforma:

- Upload do Áudio Amostra:** O cliente envia um áudio de 3 a 30 segundos (MP3, WAV, OGG, M4A ou gravação direta do microfone).
- Validação & Limpeza:** O sistema checa ruído, duração mínima e converte para PCM WAV mono a 22.050 Hz.
- Extração de Speaker Embedding:** O XTTS v2 processa o áudio e gera os tensores latentes de fonação do locutor.
- Isolamento Multi-Tenant:** Um arquivo JSON de metadados é criado registrando o `tenant_id` do proprietário.
- Backup em Nuvem (Cloudflare R2):** Se ativado, o áudio é sincronizado para o bucket R2 seguro, permitindo recuperação instantânea em caso de migração de servidor.

4.3 Studio Preview vs. Disparo no WhatsApp / CRM

Prévia no Estúdio (/germani ou /ai-agents):
Volátil e ultrarrápida. Os bytes de áudio são convertidos em Base64 na memória RAM e o arquivo temporário é deletado na hora do disco (`output_path.unlink()`).
Não acumula lixo no banco de dados e usa `no_cache: true` para garantir que cada teste seja gerado ao vivo com os sliders da tela.

Disparo no Chat / WhatsApp Direct:
Persistente e seguro. O arquivo de áudio final sintetizado é enviado para o bucket de mídia permanente gerando uma URL segura. O áudio é convertido com o codec oficial Opus (`audio/ogg; codecs=opus`) para que a Meta entregue ao celular do cliente como uma nota de voz verde nativa com forma de onda reproduzível.